

O Problema do Clique e sua Aplicação em Análise de Propagação Viral

Paulo E. R. Araujo¹, Guilherme A. Avelino²

¹Universidade Federal do Piauí – UFPI
Teresina – PI – Brasil

pumbadeveloper@gmail.com

Abstract. *This article presents the clique problem in graphs, its theoretical relevance, and a practical implementation in multcategory analysis to identify cohesive viral propagation nuclei in social networks. We propose and implement a case study in TypeScript in which seed users are modeled as content creators whose audience networks overlap and mutually reinforce each other. Users and their preferences are generated deterministically with a fixed seed, enabling reproducible experiments. For each category of interest, a graph is constructed and the maximum clique is found using an exact brute-force algorithm with early termination, running in $O(2^n \cdot n^2)$ time. Categories are ranked by clique size and, as a tiebreaker, by the aggregate reach (follower count) of clique members. An interactive HTML report is generated with graph visualizations (vis.js) and comparison charts (Chart.js). Results on the default instance confirm that the animals category yields the highest viral seed potential, with a clique of size 4 and aggregate reach of 1,201,515 followers.*

Resumo. *Este artigo apresenta o problema do clique em grafos, sua relevância teórica e uma implementação prática em análise multicategoria para identificação de núcleos coesos de propagação viral em redes sociais. Propõe-se e implementa-se um estudo de caso em TypeScript no qual os usuários seed são modelados como criadores de conteúdo cujas redes de audiência se sobrepõem e se reforçam mutuamente. Usuários e preferências são gerados de forma determinística com semente fixa, possibilitando experimentos reproduzíveis. Para cada categoria de interesse, constrói-se um grafo e busca-se o clique máximo por meio de algoritmo exato de força bruta com terminação antecipada, com complexidade $O(2^n \cdot n^2)$. As categorias são ranqueadas pelo tamanho do clique e, como desempate, pelo alcance agregado (número de seguidores) dos membros do clique. Um relatório HTML interativo é gerado com visualizações dos grafos (vis.js) e gráficos comparativos (Chart.js). Os resultados na instância padrão confirmam que a categoria animals apresenta o maior potencial de seed viral, com clique de tamanho 4 e alcance agregado de 1.201.515 seguidores.*

1. Introdução

O problema do clique em grafos é um dos temas centrais em teoria da computação e ciência de dados, com aplicações que vão desde biologia computacional até análise de re-

des sociais. Em termos práticos, identificar subconjuntos altamente conectados de entidades pode revelar núcleos de influência, comunidades coesas ou grupos com maior potencial de propagação de informação. Este trabalho apresenta e implementa uma descrição detalhada do problema do clique e propõe uma aplicação prática baseada em análise multicategoria para estimar suscetibilidade de engajamento viral em redes sociais.

A motivação central é a seguinte: em campanhas de marketing digital segmentadas, o objetivo não é simplesmente alcançar o maior número de pessoas, mas encontrar o grupo mais coeso de usuários que compartilham um interesse e se comunicam ativamente entre si. Esse grupo forma o núcleo ideal de disseminação orgânica — o *seed* viral. Formalmente, esse núcleo corresponde ao maior clique do grafo de interações de cada categoria de interesse.

O trabalho é acompanhado de uma implementação funcional completa em TypeScript, capaz de gerar instâncias aleatórias reproduzíveis, construir os grafos por categoria, resolver o problema do clique máximo de forma exata e produzir um relatório HTML interativo com visualização dos grafos e comparativo entre categorias.

2. O Problema do Clique

Seja $G = (V, E)$ um grafo não direcionado, onde V é o conjunto de vértices e E o conjunto de arestas. Um **clique** é um subconjunto $V' \subseteq V$ tal que todo par de vértices em V' está conectado por uma aresta em E . Em outras palavras, um clique é um subgrafo completo de G . O tamanho do clique é dado pelo número de vértices em V' .

O problema do clique pode ser formulado de duas formas principais:

- **Decisão:** dado um grafo G e um inteiro k , decidir se existe um clique de tamanho k em G .
- **Otimização:** encontrar o maior clique em G .

Ambas as versões são de grande interesse prático, mas a otimização é especialmente relevante para aplicações que buscam identificar o maior núcleo coeso possível. O problema do clique é conhecido por ser NP-completo [Karp 1972], o que significa que não se conhece algoritmo polinomial para resolvê-lo em geral.

A prova de NP-completude baseia-se em uma redução polinomial a partir do 3-CNF-SAT [Cormen et al. 2022]: dada uma fórmula booleana com k cláusulas, constrói-se um grafo cujos vértices são os literais de cada cláusula e cujas arestas conectam literais de cláusulas distintas que não são complementares entre si. Demonstra-se que a fórmula é satisfatível se e somente se o grafo resultante contém um clique de tamanho k . Essa equivalência fundamenta a dificuldade computacional do problema e motiva o uso de algoritmos de força bruta em instâncias de pequeno porte, bem como de heurísticas em cenários reais de grande escala [Feige et al. 1991].

3. Aplicação Prática: Engajamento Viral em Rede Social

Propomos uma aplicação do problema do clique para análise de suscetibilidade de engajamento viral em redes sociais. O objetivo é, dado um conjunto de usuários e múltiplas categorias de interesse (ex.: gosta de animais, esportes, tecnologia), identificar para cada categoria o maior grupo de usuários totalmente conectados (maior clique), estimando assim o potencial de propagação orgânica de campanhas segmentadas.

A intuição por trás da modelagem parte de uma premissa comportamental: os candidatos ao papel de *seed* são criadores de conteúdo — influenciadores, produtores de nicho — capazes de mobilizar suas audiências em torno de um tema de interesse. Ao receber e publicar um conteúdo patrocinado, cada criador expõe a campanha à sua base de seguidores. O potencial viral, contudo, não emerge do alcance isolado de um criador, mas do **reforço cruzado** entre audiências: quando as redes de dois criadores se conectam e interagem entre si, um seguidor exposto à mensagem por um criador a reencontra, reforçada, nos canais de outro. Essa exposição múltipla a fontes distintas, porém confiáveis, age sobre o psicológico do usuário — aumentando sua propensão a aderir à campanha e a recomendar o produto ao próprio círculo social, formando uma rede de recomendação orgânica.

O escore de interação s_{uv} abstrai exatamente esse grau de conectividade entre as redes de dois criadores: quanto maior s_{uv} , mais as audiências de u e v se sobrepõem e têm potencial de reforçar mutuamente a mesma mensagem. Uma aresta $(u, v) \in E_a$ indica, portanto, que as redes de u e v estão suficientemente conectadas para que o efeito de reforço seja relevante. Um grupo de criadores que forma um clique nesse grafo possui, por definição, todas as suas audiências mutuamente interconectadas, constituindo uma rede densa de recomendação que maximiza tanto a cobertura quanto a intensidade do reforço. O alcance agregado R_a estima o tamanho total da audiência atingível por esse núcleo.

4. Modelagem Formal da Aplicação

Seja U o conjunto de usuários e A o conjunto de categorias. Cada usuário $u \in U$ possui um vetor de preferências binárias $pref(u, a) \in \{0, 1\}$ para cada $a \in A$, e um alcance $reach(u) \in \mathbb{Z}^+$ que representa o número de seguidores.

Para cada categoria $a \in A$, define-se o grafo $G_a = (V_a, E_a)$, onde:

- $V_a = \{u \in U \mid pref(u, a) = 1\}$ é o subconjunto de usuários com interesse na categoria a ;
- $(u, v) \in E_a$ se e somente se o escore de interação $s_{uv} \geq \tau$, sendo τ um limiar definido.

O objetivo é encontrar, para cada $a \in A$, o maior clique $C_a^* \subseteq V_a$. O alcance agregado do clique é definido como:

$$R_a = \sum_{u \in C_a^*} reach(u)$$

O ranking das categorias é determinado primeiramente por $|C_a^*|$ (tamanho do clique) em ordem decrescente e, em caso de empate, por R_a (alcance agregado) também em ordem decrescente.

5. Metodologia do Estudo

A metodologia adotada segue as etapas abaixo:

1. **Geração da instância:** criar aleatoriamente um conjunto de usuários U e respostas binárias para cada categoria $a \in A$, com escore de interação pairwise $s_{uv} \in [0, 1]$.

2. **Construção dos grafos:** para cada categoria a , filtrar os usuários elegíveis V_a e construir G_a adicionando arestas onde $s_{uv} \geq \tau$.
3. **Solução do clique máximo:** aplicar o algoritmo de busca exata em cada G_a , obtendo C_a^* .
4. **Ranking:** ordenar as categorias por $|C_a^*|$ e, como desempate, por R_a .
5. **Relatório:** gerar relatório HTML interativo com visualizações dos grafos e gráficos comparativos.

Os parâmetros padrão utilizados no estudo de caso são: $|U| = 30$ usuários, $|A| = 5$ categorias (*animals, sports, technology, music, food*), probabilidade de preferência $p = 0,5$, limiar de interação $\tau = 0,6$ e semente determinística 42. Todos esses parâmetros são centralizados no arquivo `config.ts`, que serve como ponto único de configuração da simulação: alterar seus valores e executar novamente o sistema é suficiente para explorar diferentes cenários sem modificar a lógica de análise.

6. Implementação

A implementação foi desenvolvida em TypeScript, organizada em módulos com responsabilidades bem definidas: `models.ts` (interfaces e tipos), `generator.ts` (geração de instâncias), `graph.ts` (estrutura de dados do grafo), `solver.ts` (algoritmo de clique máximo), `analyzer.ts` (orquestração da análise) e `report.ts` (geração do relatório HTML).

6.1. Geração de Instâncias

A classe `InstanceGenerator` utiliza o algoritmo Mulberry32 como gerador pseudo-aleatório (PRNG) determinístico. Dado um valor de semente, o gerador produz a mesma sequência de números a cada execução, garantindo que os experimentos sejam reproduzíveis. Para cada par de usuários (u, v) , é gerado um escore de interação $s_{uv} \in [0, 1]$, armazenado com chave canônica $\min(u, v), \max(u, v)$ para garantir acesso simétrico eficiente.

6.2. Representação do Grafo

A classe `Graph` representa o grafo por lista de adjacências utilizando `Map<number, Set<number>>`, estrutura que oferece operações de inserção e consulta de arestas em tempo $O(1)$ amortizado. As arestas são armazenadas simetricamente (tanto $u \rightarrow v$ quanto $v \rightarrow u$), e o contador de arestas é mantido explicitamente para evitar recomputação. A construção de G_a consiste em filtrar os usuários por preferência e percorrer todos os pares elegíveis, adicionando a aresta (u, v) sempre que $s_{uv} \geq \tau$.

6.3. Algoritmo de Clique Máximo

A classe `CliqueSolver` implementa um algoritmo exato de força bruta com terminação antecipada. O algoritmo enumera subconjuntos de vértices em ordem decrescente de tamanho — de $|V_a|$ até 1 — e retorna o primeiro subconjunto que constitui um clique. Como a enumeração inicia pelo maior tamanho possível, o primeiro clique encontrado é necessariamente o máximo.

A enumeração de combinações é implementada como um gerador *lazy* por retrocesso recursivo (*backtracking*), o que evita a alocação antecipada de todos os subconjuntos em memória. A verificação de clique testa todos os pares do subconjunto em $O(k^2)$,

onde k é o tamanho do subconjunto. A complexidade global do algoritmo é $O(2^n \cdot n^2)$, sendo adequado para grafos com $|V_a| \leq 25$ vértices, conforme o perfil das instâncias geradas neste trabalho.

Para comparação, o algoritmo de Bron-Kerbosch [Bron and Kerbosch 1973] oferece uma alternativa de retrocesso com melhor desempenho em média ao podar ramos não promissores via pivoteamento, mas o algoritmo de força bruta foi adotado aqui por sua clareza conceitual e adequação ao tamanho das instâncias de estudo.

6.4. Análise e Ranking

A classe `ViralAnalyzer` orquestra o fluxo completo: para cada categoria $a \in A$, constrói G_a , executa o `CliqueSolver` e calcula o alcance agregado $R_a = \sum_{u \in C_a^*} reach(u)$. Ao final, as categorias são ordenadas por $|C_a^*|$ decrescente e R_a como critério de desempate, produzindo o ranking de potencial viral.

6.5. Relatório Visual

A classe `ReportGenerator` produz um arquivo HTML auto-contido com três tipos de visualização: (i) gráficos de barras comparando $|C_a^*|$ e R_a entre categorias, gerados com `Chart.js`; (ii) uma tabela de todos os usuários, destacando os membros de algum clique máximo; e (iii) uma visualização interativa do grafo G_a para cada categoria, gerada com `vis.js`, em que os nós do clique são destacados em laranja e os demais em azul.

Para evitar defeitos de renderização em contêineres inicialmente ocultos, a inicialização dos grafos `vis.js` é realizada de forma *lazy*: a função de construção de cada grafo é armazenada em um dicionário e executada somente na primeira vez que o usuário navega até a aba da categoria correspondente.

7. Resultados

Executando o sistema com os parâmetros padrão — semente 42, 30 usuários, 5 categorias, $\tau = 0,6$ — obtêm-se os resultados apresentados na Tabela 1.

Tabela 1. Resultados por categoria (instância padrão: 30 usuários, $\tau = 0,6$, semente 42)

Categoria	$ V_a $	$ E_a $	$ C_a^* $	R_a (seguidores)
animals	18	65	4	1.201.515
technology	15	36	4	851.826
food	15	40	4	842.877
sports	20	76	4	538.537
music	9	15	3	655.851

Quatro das cinco categorias apresentaram clique máximo de tamanho 4; a categoria *music*, com menor grafo ($|V_a| = 9$), atingiu clique de tamanho 3 e ficou em último lugar no ranking de potencial viral, apesar de possuir alcance agregado superior ao de *sports*. Isso ilustra o comportamento do critério de desempate: o tamanho do clique é o fator primário de ranqueamento, e o alcance agregado apenas diferencia categorias empatadas.

A categoria *animals* liderou o ranking com clique de tamanho 4 e alcance agregado de 1.201.515 seguidores, sendo a recomendação do sistema como melhor alvo para uma campanha de *seed* viral. Os quatro membros do clique — User 1 (300.950 seguidores), User 5 (134.211), User 10 (463.992) e User 22 (302.362) — formam um subgrafo completamente conectado dentro do subgrafo de interessados em *animals*, representando o núcleo ideal de disseminação para campanhas segmentadas nessa categoria.

O relatório HTML gerado permite inspecionar visualmente cada grafo G_a , navegar entre categorias e verificar quais usuários compõem o clique máximo de cada segmento, facilitando a interpretação e comunicação dos resultados para equipes de marketing.

8. Conclusão

Este trabalho apresentou o problema do clique em grafos, demonstrou sua NP-completude e propôs e implementou uma aplicação prática para identificação de núcleos coesos de propagação viral em redes sociais.

A implementação completa em TypeScript compreende: geração determinística e reproduzível de instâncias, representação eficiente do grafo por lista de adjacências, algoritmo exato de clique máximo por força bruta com terminação antecipada ($O(2^n \cdot n^2)$), análise multicategoria com ranking por tamanho de clique e alcance agregado, e geração de relatório HTML interativo. Os experimentos realizados sobre a instância padrão confirmam a viabilidade da abordagem para redes de pequeno e médio porte, produzindo resultados interpretáveis e visualmente acessíveis.

A principal limitação do método é a complexidade exponencial do algoritmo de força bruta, que se torna inviável para grafos com dezenas de vértices. Em cenários reais com milhares de usuários por categoria, seriam necessárias abordagens heurísticas — como o algoritmo de Bron-Kerbosch com pivoteamento [Bron and Kerbosch 1973], algoritmos gulosos ou metaheurísticas como *simulated annealing* — que oferecem soluções de boa qualidade em tempo polinomial, ainda que sem garantia de ótimo global.

Como trabalhos futuros, aponta-se: (i) a substituição do solver exato por uma heurística escalável; (ii) a incorporação de grafos ponderados, em que o escore de interação s_{uv} influencie diretamente o ranking em vez de apenas determinar a existência da aresta; e (iii) a avaliação em grafos reais provenientes de plataformas de redes sociais. O problema do clique oferece, assim, uma lente rigorosa e matematicamente fundamentada para identificar os núcleos com maior potencial de propagação orgânica em qualquer segmento de interesse.

Referências

- Bron, C. and Kerbosch, J. (1973). Algorithm 457: Finding all cliques of an undirected graph. *Communications of the ACM*, 16(9):575–577.
- Cormen, T. H., Leiserson, C. E., Rivest, R. L., and Stein, C. (2022). *Introduction to Algorithms*. MIT Press, 4th edition. Seção 34.5.1, Teorema 34.11, pp. 1081–1084.
- Feige, U., Goldwasser, S., Lovász, L., Safra, S., and Szegedy, M. (1991). Approximating clique is almost NP-complete. In *Proceedings of the 32nd Annual Symposium on Foundations of Computer Science*, pages 2–12.

Karp, R. M. (1972). Reducibility among combinatorial problems. In Miller, R. E. and Thatcher, J. W., editors, *Complexity of Computer Computations*, pages 85–103. Plenum Press.